

基于几何教师与残差强化学习的 Franka 机械臂高精度插孔控制研究

王思诚

2026.08.21

摘要

本文面向 Franka 机械臂高精度圆棒插孔任务，研究存在几何间隙约束、安装偏差、观测误差与执行扰动条件下的稳定插入控制问题。仿真任务由随机单孔插入扩展至 2×3 六孔阵列指定目标孔插入：圆柱棒直径 20 mm、孔径 23 mm，目标孔或孔阵列在约 $10 \text{ cm} \times 10 \text{ cm}$ 工作空间内随机初始化，同时 Peg 相对末端法兰的 X/Y 安装偏移在每回合重置时随机采样，范围为 $\pm 5 \text{ mm}$ ，用于模拟工具安装误差，并限制策略直接获取无噪声绝对棒/孔位姿。

针对接触约束下从零强化学习探索效率低、训练过程易破坏已有稳定控制行为的问题，本文构建“解析几何教师 + 有界残差强化学习”的分层控制框架。首先根据棒尖与目标孔之间的相对位移、插入深度和姿态误差构造三阶段几何教师，并通过六维操作空间控制实现接近、对准和插入；随后冻结教师策略，由 PPO 学习幅值受限的残差动作，以补偿孔位估计偏置、动作噪声和控制增益变化。针对六孔任务，在状态中进一步引入目标孔 one-hot 条件，使策略能够在六个碰撞孔同时存在时完成指定目标插入。

实验结果表明，在基准工况下，单孔任务与六孔任务均可达到 $512/512 = 100\%$ 的成功率。在包含回合级固定 XY 孔位估计偏置、动作噪声和 5% 增益扰动的强扰动工况下，单孔几何教师成功率为 92.97%，500 轮 Residual PPO 提升至 96.88%；六孔任务在更高动作噪声 0.0305 下，几何教师成功率为 85.94%，Residual PPO 达到 $128/128 = 100\%$ ，绝对提升 14.06 个百分点。结果表明，几何教师能够提供稳定的名义运动行为，而有界残差策略能够在不破坏基本插入逻辑的前提下提高对系统偏差与随机执行扰动的适应能力。

关键词： Franka 机械臂；精密插孔；操作空间控制；几何教师；残差强化学习；PPO；扰动补偿

（一）研究任务与问题建模 本部分从研究问题出发说明任务约束、仿真模型、观测与动作空间以及统一性能判据。

1. 研究背景与任务描述

1.1. 研究背景

机器人插孔装配属于典型的接触丰富型精密操作任务。与自由空间运动相比，插入过程除受到末端定位精度影响外，还同时受孔棒几何间隙、接触摩擦、棒轴倾斜、安装偏差以及目标位姿估计误差等因素制约。当孔棒间隙较小时，毫米级横向误差即可引起孔口碰撞或卡滞，因此控制器既需要保证自由空间阶段的快速收敛，又需要在孔口附近具备足够细致的姿态与位置调节能力。

本项目设置两个递进任务：

1. **随机单孔插入：**控制 Franka 机械臂将直径 20 mm 的圆柱 Peg 插入直径 23 mm 的目标孔。目标孔在约 $10\text{ cm} \times 10\text{ cm}$ 范围内随机，Peg 相对末端法兰存在约 $\pm 5\text{ mm}$ 安装不确定性，要求在受限观测条件下实现不低于 90% 的插入成功率。
2. **六孔指定目标插入：**将目标扩展为 2×3 六孔阵列，孔间距 30 mm，阵列整体位置随机，并根据给定目标孔编号完成指定孔插入。六个孔在整个回合中同时保留真实碰撞几何。

1.2. 关键技术问题

结合任务约束，本文重点处理以下问题：

- **精密几何约束：**20 mm 棒径与 23 mm 孔径对应的可容许径向偏差较小；
- **接触阶段姿态保持：**插入过程中既需减小横向误差，又需约束棒轴倾角与插入深度；
- **观测不确定性：**策略不能依赖无噪声绝对孔位姿，需要在存在估计偏置的相对观测下工作；
- **执行扰动：**安装偏差、动作噪声与控制增益变化会降低解析控制器的重复精度；
- **多目标条件控制：**六孔场景下需要根据目标编号形成条件策略，而非简单重复单孔控制；

- **可比性评估：**不同方法的性能必须在相同时间预算、扰动水平和成功判据下进行比较。

1.3. 研究思路

本文采用“几何先验负责名义运动，强化学习负责局部补偿”的设计思路。首先通过仿真模型与几何关系校核确认插入任务的物理可达性，并构建具有明确阶段逻辑的解析几何教师；随后将教师冻结，以其输出作为名义动作，仅训练 Residual PPO 学习小幅动作修正。该方法避免直接从随机策略开始探索接触过程，同时使强化学习带来的性能增益能够相对于固定教师基线进行量化。

2. 仿真任务建模

2.1. 机器人与孔棒几何

仿真采用 Franka 7 自由度机械臂开发模型，末端安装长度 100 mm、半径 10 mm 的圆柱 Peg。Peg 通过 X/Y 两个安装偏移自由度描述抓取安装不确定性，对应偏移范围为 ± 5 mm。当前机器人资产基于 Isaac Lab Franka Panda USD 构建，作为正式 FR3 模型导入前的仿真替代模型，因此本文结论限定于当前 Isaac Lab 动力学环境。单孔和阵列孔的开口直径均为 23 mm。孔口采用 36 段实体环形壁构建碰撞边界，以保证孔壁不仅具有视觉几何，还能够参与真实接触计算。

2.2. 随机单孔与六孔阵列

单孔任务中，目标孔在约 $10\text{ cm} \times 10\text{ cm}$ 的可达区域内随机。强扰动评估时，在每个回合开始时对孔位相对观测叠加固定 XY 偏置：

$$\mathbf{b}_{xy} \sim \mathcal{N}(\mathbf{0}, \sigma_h^2 \mathbf{I}), \quad \sigma_h = 0.5\text{ mm}. \quad (1)$$

该偏置在单个回合内保持不变，用于近似视觉标定误差或目标位置估计中的系统性偏差。

六孔任务包含 2 行 3 列共 6 个孔，孔中心间距为 30 mm，六孔相对位置固定，阵列整体在相同工作空间内随机平移。每个回合随机或指定目标孔 $i \in \{0, 1, \dots, 5\}$ ，目标编号以 6 维 one-hot 向量输入策略。该设置要求控制器在非目标孔碰撞几何同时存在的情况下完成目标选择与插入。

六孔阵列的几何布局与整体随机化方式如图1所示。图中 0-5 表示固定的孔编号，橙色圆表示当前目标孔，虚线方框表示阵列原点的 $100\text{ mm} \times 100\text{ mm}$ 随机化范围。随机化仅改变阵列整体位置，不改变六孔之间 30 mm 的相对间距，因此

能够在保持场景拓扑不变的条件下考察目标条件控制与 workspace 位置变化带来的影响。




图 1: 2×3 六孔阵列布局、目标孔编号、30 mm 孔间距及阵列原点在 $100 \text{ mm} \times 100 \text{ mm}$ 工作空间内的随机化范围。

2.3. 观测与动作空间

单孔任务的策略观测定义为

$$\mathbf{o}_t = [\mathbf{q}_t, \dot{\mathbf{q}}_t, \Delta \mathbf{p}_{\text{peg-hole},t}, \mathbf{e}_{\text{tilt},t}, \mathbf{a}_{t-1}], \quad (2)$$

其中 $\mathbf{q}_t \in \mathbb{R}^9$ 与 $\dot{\mathbf{q}}_t \in \mathbb{R}^9$ 分别表示关节位置和速度， $\Delta \mathbf{p}_{\text{peg-hole},t} \in \mathbb{R}^3$ 表示棒尖相对目标孔的位置误差， $\mathbf{e}_{\text{tilt},t} \in \mathbb{R}^3$ 表示棒轴倾斜信息， $\mathbf{a}_{t-1} \in \mathbb{R}^6$ 表示上一时刻动作。因此单孔观测维度为 30；六孔任务进一步加入目标孔条件 $\mathbf{c}_i \in \mathbb{R}^6$ ，总观测维度为 36。

策略不读取隐藏的 Peg 安装偏移关节，也不直接读取无噪声绝对孔位姿。动作 $\mathbf{a}_t \in \mathbb{R}^6$ 为末端相对位姿增量，包括三维平移与三维旋转修正，由六维操作空间控制器转换为机器人执行命令。

2.4. 成功判据与评价指标

设终端径向误差为 e_r 、插入深度为 d 、棒轴倾角为 θ ，成功事件定义为

$$\mathcal{S} = \{e_r \leq 1.3 \text{ mm}\} \cap \{15 \text{ mm} \leq d \leq 40 \text{ mm}\} \cap \{\theta \leq 2^\circ\} \cap \{\text{未发生工作空间越界}\}. \quad (3)$$

每个回合最大持续时间为 20 s，即 600 个 30 Hz 控制步。主要评价指标为插入成功率

$$S = \frac{N_{\text{succ}}}{N_{\text{all}}} \times 100\%, \quad (4)$$

并同步统计超时、过深插入以及终端径向误差、插入深度和棒轴倾角。所有方法均采用相同的成功判据，避免因终止条件差异造成结果偏差。

2.5. 主要符号说明

为避免状态量、几何误差、任务奖励与 PPO 优化量之间产生符号混淆，本文主要符号统一列于表1。其中径向误差统一记为 $e_{r,t}$ ，标量 r_t 仅用于表示强化学习任务奖励。

表 1: 本文主要公式符号及含义。

符号	含义	符号	含义
t	离散控制时刻/策略步	$\mathbf{q}_t, \dot{\mathbf{q}}_t$	关节位置与关节速度向量
$\Delta \mathbf{p}_{\text{peg-hole},t}$	Peg 棒尖相对目标孔的位置误差	$\mathbf{e}_{\text{tilt},t}$	Peg 轴相对孔轴的倾斜表示
$\mathbf{c}_i$	六孔任务中目标孔 i 的 one-hot 条件	$e_{r,t}$	Peg 棒尖相对孔中心的径向误差
d_t	插入深度, 沿孔轴向下为正	θ_t	Peg 轴与孔轴之间的倾角
$d_{xy,t}$	Peg 与目标孔在 XY 平面的距离	$\tilde{\mathbf{e}}_{xy,t}$	几何教师使用的带误差 XY 位置误差
$\tilde{\mathbf{e}}_{R,t}$	几何教师使用的姿态误差	$\mathbf{a}_t^T$	冻结解析几何教师输出的名义动作
$\delta \mathbf{a}_t$	Residual PPO 学习的有界残差动作	$\boldsymbol{\mu}_t$	高斯策略动作分布的均值
$\mathbf{a}_t$	策略采样得到的六维归一化动作	$\tilde{\mathbf{a}}_t$	加入增益扰动和动作噪声后的执行动作
α	残差缩放系数, 本文取 0.15	$f_\phi(\cdot)$	参数为 ϕ 的残差神经网络
r_t	时刻 t 的标量任务总奖励	$r_t^{(j)}, w_j$	第 j 个奖励分量及其权重
$\Phi(\cdot)$	精细对准的高斯势函数	g_t	插入进度奖励的门控函数
$\rho_t(\phi)$	PPO 中新旧策略的概率比	$\hat{A}_t$	时刻 t 的优势函数估计
ϵ	PPO 截断参数	$\mathcal{L}_{\text{clip}}$	PPO 截断代理损失
$\mathcal{L}_V$	价值函数损失	$\mathcal{H}(\pi_\phi)$	策略熵
$\mathcal{L}_R$	有界残差动作正则项	λ_R	残差正则系数, 本文取 100
$\mathbf{b}_{xy}, \sigma_h$	回合级 XY 孔位估计偏置及其标准差	g_e	回合级动作增益扰动系数
$\boldsymbol{\epsilon}_t, \sigma_a$	控制步动作噪声及其标准差	S	独立评估中的插入成功率
k_p, k_R	几何教师的位置与姿态比例增益	$v_z(\cdot)$	几何教师的轴向速度函数
σ_r	精细对准高斯势函数的尺度参数	e_g, θ_g	插入进度奖励的径向/姿态门限
d_0, d_a	插入进度归一化深度与动作维度	c_V, c_H	价值损失与熵项权重
$N_{\text{succ}}, N_{\text{all}}$	成功回合数与总评估回合数	$\mathbb{I}(\cdot), \mathbf{I}$	指示函数与单位矩阵

为便于在进入具体算法之前把握各模块之间的关系, 本文整体控制与训练流程如图2所示。任务随机化与扰动首先形成受限策略观测; 同一观测同时输入冻

结的三阶段几何教师和 Residual PPO 分支。几何教师负责生成可解释的名义接近、对准与插入动作，残差网络仅输出幅值受限的局部修正，两者叠加后由六维 Pose OSC 转换为机器人执行命令。训练阶段仅通过 PPO 更新残差网络，几何教师保持冻结；在确定性评估阶段，训练优化支路不再参与在线计算，仅保留“观测-教师/残差-动作执行”的前向控制链。




图 2: 基于解析几何教师与有界 Residual PPO 的整体控制与训练框架。实线表示执行阶段的主控制信息流，虚线表示仅在训练阶段使用的策略优化信息流。

(二) 控制方法与学习框架 本部分给出操作空间控制、三阶段几何教师、有界残差策略、任务奖励函数、Residual PPO 优化目标以及扰动建模方法。

1. 几何教师与操作空间控制

1.1. 六维操作空间控制

物理仿真频率为 120 Hz，控制降采样系数为 4，因此策略与操作空间控制频率均为 30 Hz。控制器同时调节末端三维位置和三维姿态，并利用零空间项抑制冗余自由度漂移。主要物理与控制参数见表2。

表 2: 主要物理与控制参数。

参数	设置
物理仿真步长	1/120 s
控制降采样系数	4
策略控制周期	1/30 s
位置求解器迭代次数	16
速度求解器迭代次数	4
增强确定性设置	开启
零空间刚度	20

前期调试表明，仅采用不完整位置控制时，腕部冗余姿态变化会放大棒尖 XY 摆动。通过检查雅可比条件、末端姿态以及 Peg 轴向方向后，最终采用完整六维 Pose OSC 作为底层控制器，以同时约束位置和姿态。

1.2. 三阶段几何教师

为适应自由空间接近与孔口精调之间不同的控制需求，将教师策略划分为三个阶段：

- 1. **接近阶段 (Approach)**：在孔口上方保持安全高度，优先减小较大的 XY 位置误差；
- 2. **对准阶段 (Align)**：接近孔口后降低平移速度，进一步减小径向误差并校正棒轴姿态；

3. **插入阶段 (Insert)**: 当径向误差与倾角满足对准条件后, 沿孔轴方向下插。

记带误差观测得到的 XY 位置误差为 $\tilde{e}_{xy,t}$, 姿态误差为 $\tilde{e}_{R,t}$, 教师动作可写为

$$\mathbf{a}_t^T = \text{clip} \left(\begin{bmatrix} k_p \tilde{e}_{xy,t} \\ v_z(\tilde{e}_{r,t}, d_t) \\ k_R \tilde{e}_{R,t} \end{bmatrix}, -1, 1 \right), \quad (5)$$

其中 $\tilde{e}_{r,t}$ 表示由带误差相对观测计算得到的径向误差, v_z 由当前控制阶段、径向误差和插入深度共同决定。单孔任务的教师对准阈值为 1 mm; 六孔强扰动评估中采用 2 mm, 以适应更长的横向运动距离和更强动作扰动。

2. 有界残差强化学习

2.1. 有界残差策略结构

几何教师已经能够给出完整的接近-对准-插入名义行为, 因此强化学习不再重新生成全部控制动作, 而只学习教师动作附近的局部修正。设残差网络为 $f_\phi(\mathbf{o}_t)$, 实际施加到教师动作上的残差定义为

$$\delta \mathbf{a}_t = \alpha \tanh(f_\phi(\mathbf{o}_t)), \quad \alpha = 0.15, \quad (6)$$

其中 $f_\phi(\cdot)$ 由两层 64-64 隐藏层构成, 隐藏层采用 $\tanh$ 激活, 网络输出端进一步通过 $\tanh$ 完成显式有界化。因此每个动作维度的残差修正均限制在 $[-0.15, 0.15]$ 范围内。

冻结几何教师根据当前相对观测产生名义动作 $\mathbf{a}_t^T$, 残差策略对应高斯动作分布的均值为

$$\boldsymbol{\mu}_t = \mathbf{a}_t^T + \delta \mathbf{a}_t. \quad (7)$$

最终训练采用固定探索标准差 0.03; 确定性评估时采用动作分布均值。残差网络输出层使用零权重、零偏置初始化, 因此训练初始时 $\delta \mathbf{a}_t = \mathbf{0}$, 整体策略严格退化为解析几何教师, 随后 PPO 仅在该名义策略附近逐步学习局部补偿。教师参数与探索方差在 Residual PPO 训练期间保持冻结, critic 仍保持可训练, 以适应扰动条件下回报分布的变化。

2.2. 任务奖励函数设计

在解析几何教师已提供基本运动逻辑的前提下, 任务奖励主要用于衡量残差动作是否进一步改善目标接近、孔口对准、插入进度和任务完成质量, 并通过安

全与平滑约束抑制非期望行为。环境在时刻 t 返回的总任务奖励统一表示为

$$r_t = \sum_{j=1}^{N_r} w_j r_t^{(j)}, \quad (8)$$

其中 $r_t^{(j)}$ 表示第 j 个奖励分量, w_j 为对应权重。单孔和六孔任务均围绕“接近–对准–插入–完成”的过程设计奖励,但考虑到任务空间、已有教师能力与训练阶段不同,最终奖励组合并不完全相同,具体配置见表3。

2.2.1 单孔任务奖励

最终 23 mm 单孔任务的奖励写为

$$\begin{aligned} r_t^{\text{single}} = & 80r_{\text{app},t} + 20r_{\text{align},t} + 40r_{\text{ins},t} - 8r_{\text{jam},t} - 3r_{\text{tilt},t} \\ & + 500r_{\text{succ},t} - 100r_{\text{over},t} - 0.05r_{\text{time},t} - 0.005r_{\Delta a,t} - 5 \times 10^{-5}r_{\dot{q},t}. \end{aligned} \quad (9)$$

接近阶段采用 XY 距离的逐步改善量。定义

$$d_{xy,t} = \|\mathbf{p}_{\text{peg},t}^{xy} - \mathbf{p}_{\text{hole},t}^{xy}\|_2, \quad (10)$$

则接近进度奖励为

$$r_{\text{app},t} = d_{xy,t-1} - d_{xy,t}. \quad (11)$$

该设计只奖励进一步接近目标孔的运动,从而避免策略停留在孔附近持续获得静态距离奖励。

孔口附近采用高斯势函数描述精细对准程度:

$$\Phi(e_{r,t}) = \exp\left[-\frac{1}{2}\left(\frac{e_{r,t}}{\sigma_r}\right)^2\right], \quad \sigma_r = 3 \text{ mm}, \quad (12)$$

并使用势函数增量

$$r_{\text{align},t} = \Phi(e_{r,t}) - \Phi(e_{r,t-1}) \quad (13)$$

作为精细对准奖励,使策略只有在径向误差进一步减小时才获得正回报。

插入阶段采用门控深度进度奖励

$$r_{\text{ins},t} = g_t \text{clip}\left(\frac{d_t - d_{t-1}}{d_0}, -1, 1\right), \quad d_0 = 30 \text{ mm}, \quad (14)$$

其中

$$g_t = \mathbb{I}(e_{r,t} < e_g) \mathbb{I}(\theta_t < \theta_g). \quad (15)$$

最终 23 mm 单孔任务将径向门限设置为 $e_g = 2.0$ mm。当前奖励实现中的姿态门限 θ_g 保持较宽松的 50° ，用于保证训练阶段具有连续的插入进度信号；最终任务成功仍独立要求 $\theta \leq 2^\circ$ 。

当 Peg 尚未满足成功径向条件但已经向孔板区域下压时，定义卡滞惩罚

$$r_{\text{jam},t} = \mathbb{I}(e_{r,t} > e_{\text{tol}}) \mathbb{I}(z_{\text{peg},t} < z_{\text{hole}} + 5 \text{ mm}). \quad (16)$$

倾角惩罚定义为

$$r_{\text{tilt},t} = \text{clip}\left(\frac{\theta_t - 2^\circ}{8^\circ}, 0, 1\right), \quad (17)$$

即倾角不超过 2° 时不额外惩罚，在 2° – 10° 范围内线性增加。

成功奖励与最终几何判据保持一致：

$$r_{\text{succ},t} = \mathbb{I}(e_{r,t} \leq 1.3 \text{ mm}, 15 \text{ mm} \leq d_t \leq 40 \text{ mm}, \theta_t \leq 2^\circ), \quad (18)$$

并在 $d_t > 42$ mm 时触发过深插入惩罚 $r_{\text{over},t}$ 。此外，每个控制步施加固定时间成本，并使用截断后的动作变化平方项 $r_{\Delta a,t}$ 与关节速度平方项 $r_{\dot{q},t}$ 提高运动平滑性、抑制仿真接触尖峰引起的数值异常。

2.2.2 六孔任务奖励

六孔任务在目标孔 one-hot 条件和解析教师的基础上采用更精简的奖励结构：

$$\begin{aligned} r_t^{\text{array}} = & 2r_{\text{app},t}^{\text{dense}} + 20r_{\text{align},t} + 40r_{\text{ins},t} + 100r_{\text{succ},t} \\ & - 0.01r_{\Delta a,t} - 10^{-4}r_{\dot{q},t}. \end{aligned} \quad (19)$$

其中目标接近奖励采用三维距离的稠密形式

$$r_{\text{app},t}^{\text{dense}} = \max\left(1 - \frac{\|\mathbf{p}_{\text{peg},t} - \mathbf{p}_{\text{hole},t}\|_2}{1 \text{ m}}, 0\right). \quad (20)$$

六孔任务的精细对准奖励与门控插入进度奖励沿用相同基本形式，插入径向门限为 2.5 mm；成功奖励严格要求 $e_r \leq 1.3$ mm、 $15 \leq d \leq 40$ mm 且 $\theta \leq 2^\circ$ 。最终六孔奖励未额外启用显式卡滞、倾角、时间和过深插入奖励项，而主要依赖解析几何教师、严格成功终止条件以及动作平滑项约束策略行为。

表 3: 单孔与六孔任务最终奖励配置。

奖励项	单孔任务权重	六孔任务权重	主要作用
目标接近	80 (进度型)	2 (稠密型)	引导 Peg 接近目标孔
精细对准	20	20	提高孔口附近径向精度
插入进度	40	40	对准后鼓励沿孔轴推进
卡滞惩罚	-8	-	抑制孔外下压
倾角惩罚	-3	-	抑制过大姿态偏差
成功奖励	500	100	强化完整插入
过深惩罚	-100	-	防止超过安全插入深度
时间成本	-0.05	-	提高任务完成效率
动作变化	-0.005	-0.01	提高动作平滑性
关节速度	-5×10^{-5}	-10^{-4}	抑制异常高关节速度

值得注意的是，两类任务奖励形式并不完全相同。单孔课程阶段加入更多安全和效率约束，以抑制早期训练中的卡滞、过深插入和姿态偏离；六孔任务在已有解析教师与目标条件的基础上使用更精简的奖励，使 Residual PPO 更集中于多目标条件变化和执行扰动下的局部补偿。两者的核心目标主要是通过 RL 提高教师附近的局部收敛与插入质量。

2.3. Residual PPO 优化目标

为避免残差策略在连续更新过程中逐渐偏离解析几何教师，本文在标准 PPO 目标基础上加入有界残差动作正则项。设新旧策略概率比为

$$\rho_t(\phi) = \frac{\pi_\phi(\mathbf{a}_t \mid \mathbf{o}_t)}{\pi_{\phi_{\text{old}}}(\mathbf{a}_t \mid \mathbf{o}_t)}, \quad (21)$$

则 PPO 截断代理损失表示为

$$\mathcal{L}_{\text{clip}} = -\mathbb{E}_t \left[\min \left(\rho_t \hat{A}_t, \text{clip}(\rho_t, 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right]. \quad (22)$$

由于实际残差已经经过输出 Tanh 和比例系数 α 限制，因此代码中的残差正则直接作用于 $\delta \mathbf{a}_t$:

$$\mathcal{L}_R = \mathbb{E}_t \left[\frac{1}{d_a} \|\delta \mathbf{a}_t\|_2^2 \right], \quad d_a = 6. \quad (23)$$

最终 Residual PPO 优化目标为

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{clip}} + c_V \mathcal{L}_V - c_H \mathcal{H}(\pi_\phi) + \lambda_R \mathcal{L}_R, \quad (24)$$

其中 $\mathcal{L}_V$ 为价值函数损失, $\mathcal{H}$ 为策略熵, c_V 与 c_H 分别为对应权重。最终实验取 $\lambda_R = 100$ 、 $c_H = 0$, 并采用 10^{-5} 的学习率与每轮 1 次 PPO 更新, 以降低策略在稳定教师附近产生过大漂移的风险。

3. 不确定性与扰动建模

研究过程中分别考虑了观测误差、孔位估计偏置、动作噪声、控制增益变化以及 Peg 安装偏差等不确定因素。最终单孔和六孔训练均显式采用: 每回合固定的 XY 孔位估计偏置、逐控制步动作噪声以及回合级控制增益扰动; 几何教师专用的相对位置与倾角附加噪声在两组最终 run 配置中均设为 0。

回合级孔位估计偏置表示为

$$\mathbf{b}_{xy} \sim \mathcal{N}(\mathbf{0}, \sigma_h^2 \mathbf{I}), \quad \sigma_h = 0.5 \text{ mm}, \quad (25)$$

并在一个回合内保持不变, 以近似视觉标定或目标定位产生的系统性偏差。动作执行扰动表示为

$$\tilde{\mathbf{a}}_t = g_e \mathbf{a}_t + \boldsymbol{\epsilon}_t, \quad g_e \sim \mathcal{N}(1, 0.05^2), \quad \boldsymbol{\epsilon}_t \sim \mathcal{N}(0, \sigma_a^2 \mathbf{I}), \quad (26)$$

其中最终训练采用 $\sigma_a = 0.02$ 。六孔最终强扰动评估进一步将动作噪声提高至 0.0305, 以检验超出训练扰动水平后的性能。此外, Peg 相对末端法兰的 X/Y 安装偏差通过物理模型在每回合重置时采样。所有最终主线训练与评估均保持动作延迟为 0。

(三) 实验设计与结果分析 本部分给出训练参数、TensorBoard 训练动态、独立评估工况和最终性能结果，并重点分析有界残差在强扰动条件下的实际作用。

1. 实验设计

1.1. 软件与硬件环境

表 4: 软件与硬件配置。

项目	配置
操作系统	Ubuntu 22.04.5 LTS
GPU	NVIDIA RTX 5880 Ada, 48 GB VRAM
NVIDIA 驱动	580.173.02
Python	3.10.20
Isaac Sim	4.5.0
Isaac Lab	2.1.0
PyTorch	2.5.1
Gymnasium	1.3.0
RSL-RL	2.3.3

1.2. 训练设置

单孔和六孔 Residual PPO 均训练 500 轮，每轮使用 1024 个并行环境、每环境 64 个采样步，随机种子均为 42。两类任务保持基本一致的优化配置，以减少超参数差异对结果比较的影响；主要差异仅体现在教师对准阈值和重置预热设置。最终训练参数见表5。

表 5: Residual PPO 最终训练参数。

参数	单孔任务	六孔任务
并行环境数	1024	1024
训练轮数	500	500
采样步数/环境	64	64
随机种子	42	42
学习率	1×10^{-5}	1×10^{-5}
每轮 PPO 更新次数	1	1
固定探索标准差	0.03	0.03
熵系数	0	0
残差正则系数 λ_R	100	100
残差缩放系数 α	0.15	0.15
回合级 XY 孔位估计偏置标准差	0.5 mm	0.5 mm
训练动作噪声标准差	0.02	0.02
控制增益扰动	5%	5%
教师对准阈值	1 mm	2 mm
重置预热步数	20	0

1.3. 训练过程与残差幅值分析

为分析 Residual PPO 在解析教师附近的训练特性，本文从任务 1 和任务 2 最终 500 轮 TensorBoard 记录中提取平均回合奖励、价值函数损失及残差正则项，并使用 20 轮滑动平均展示总体变化趋势，见图3。需要指出的是，训练入口采用随机初始回合长度以打散并行环境重置同步，因此最初若干轮存在明显启动瞬态；同时，平均回合奖励综合受到回合长度、成功奖励以及安全/平滑项影响，不能直接等同于独立评估成功率。

单孔任务中，解析几何教师在训练开始前已经具备较强的名义插入能力，因此 Residual PPO 主要学习小幅局部修正。经过启动瞬态后，平均回合奖励整体维持在较窄范围，最后 50 轮均值约为 0.159。更重要的是，残差动作均方根幅值在最后 50 轮约为 2.44×10^{-3} ，仅占理论单轴残差上限 $\alpha = 0.15$ 的约 1.63%，整个训练过程中最大比例约为 1.70%。这表明单孔 Residual PPO 并未重新构造完整动作，而是在几何教师附近进行幅值很小的局部补偿。

六孔任务的训练变化更为明显：平均回合奖励在训练早期快速提高，随后稳

定在接近 40 的区间，最后 50 轮平均值约为 38.69；value loss 由前 50 轮平均约 0.82 降低至后 50 轮约 0.081，说明 critic 对条件多目标任务的回报估计逐步稳定。六孔任务最后 50 轮的残差均方根幅值约为 4.33×10^{-3} ，约占 0.15 上限的 2.89%，全程最大比例约 5.05%。即使面对目标条件变化和更长横向路径，实际残差仍远小于允许上限，从训练层面支持“几何教师负责名义控制、Residual PPO 负责局部补偿”的结构假设。




图 3: Residual PPO 训练过程与有界残差幅值变化：(a) 单孔任务平均回合奖励；(b) 六孔任务平均回合奖励；(c) 残差动作均方根幅值占理论残差上限 $\alpha = 0.15$ 的比例。浅色曲线表示原始 TensorBoard 记录，实线表示 20 轮滑动平均。

上述训练曲线仅用于解释策略更新过程与残差修正幅值，最终性能仍以固定评估工况下的独立批量测试为准。结合后续结果可以看到，幅值远低于理论上限的残差动作已经能够使单孔强扰动成功率由 92.97% 提升至 96.88%，并使六孔任务由 85.94% 提升至 100%。

1.4. 评估工况与对比方法

本文主要比较冻结几何教师与 Residual PPO。为保证比较具有直接意义，两种方法在同一任务内采用完全相同的回合时长、孔位偏置、动作噪声、增益扰动、对准阈值和成功判据。具体评估工况见表6。

表 6: 最终性能评估工况。

评估工况	回合数	孔位/观测误差	动作噪声	增益扰动	延迟	对准阈值
单孔基准工况	512	0.5 mm/0.25° 逐步均匀观测噪声	0	0	0	1 mm
单孔强扰动工况	128	回合级固定 XY 标准差 0.5 mm	0.02	5%	0	1 mm
六孔基准工况	512	0.5 mm/0.25° 逐步均匀观测噪声	0	0	0	1 mm
六孔强扰动工况	128	回合级固定 XY 标准差 0.5 mm	0.0305	5%	0	2 mm

单孔和六孔强扰动评估均使用 64 个并行环境和随机种子 42。由于最终统计主要基于单一随机种子，本文结果仅为当前固定评估设置下的性能对比。

2. 总体性能结果

单孔与六孔任务的总体性能对比如图4和表7所示。图4以 90% 任务目标线作为直观参考，并在柱顶同时标注成功率与成功回合数；表7进一步给出超时和过深插入等失败构成。两种表示共同用于区分“最终是否成功”和“失败主要发生在何种终止形式”。




图 4: 单孔与六孔任务在基准工况和强扰动工况下的插入成功率对比：(a) 单孔任务；(b) 六孔任务。

表 7: 几何教师与 Residual PPO 最终性能对比。

评估工况	方法	成功	超时	过深插入	成功率
单孔基准	几何教师	512/512	0	0	100%
单孔基准	Residual PPO	512/512	0	0	100%
单孔强扰动	几何教师	119/128	9	0	92.97%
单孔强扰动	Residual PPO (500 轮)	124/128	4	0	96.88%
六孔基准	Residual PPO	512/512	0	0	100%
六孔强扰动	几何教师	110/128	18	0	85.94%
六孔强扰动	Residual PPO (500 轮)	128/128	0	0	100%

基准工况下，解析几何教师已经能够完成稳定插入，说明由几何教师与 OSC

构成的名义控制链具有充分的任务可达性。在此基础上，强扰动工况人为扩大了孔位估计与执行误差，使教师性能下降，从而能够进一步观察 Residual PPO 是否确实学习到额外补偿能力。

3. 强扰动条件下的性能分析

3.1. 单孔任务

单孔强扰动工况中，几何教师成功 119/128，Residual PPO 成功 124/128，成功率绝对提升为

$$\Delta S_1 = \frac{124 - 119}{128} \times 100\% = 3.91 \text{ 个百分点.} \quad (27)$$

PPO 将超时回合由 9 个减少至 4 个，且两种方法均未出现过深插入。由此可见，当前单孔任务的主要失效形式并非插入深度失控，而是扰动作用下无法在有限时间内完成高精度对准；Residual PPO 主要改善了接近末期与孔口附近的收敛效率。

为给出定量结果之外的直观验证，图5展示了一条单孔强扰动成功轨迹的终止帧。可以看到 Peg 在保持近似竖直姿态的情况下进入目标孔，图中画面仅用于说明成功终态的几何关系，是否满足成功仍以式(3)的统一数值判据为准。




图 5: 单孔强扰动工况下 Residual PPO 的一条代表性成功插入终止帧。

3.2. 六孔任务

六孔强扰动工况中，几何教师成功 110/128，Residual PPO 成功 128/128，绝对提升为

$$\Delta S_2 = \frac{128 - 110}{128} \times 100\% = 14.06 \text{ 个百分点.} \quad (28)$$

与单孔相比，六孔任务额外包含目标条件输入、更长的横向移动路径以及多个非目标孔碰撞体，因此对动作扰动和目标位置误差更加敏感。Residual PPO 在该工况下消除了 18 个教师超时回合，说明局部残差补偿在多目标条件插入中具有更明显作用。

六孔 Residual PPO 全部 128 个成功回合的终端几何统计见表8，并进一步在图6中给出均值、极值与成功约束之间的关系。

表 8: 六孔 Residual PPO 成功回合的终端几何指标。

指标	均值	最小值	最大值	成功约束
插入深度	16.461 mm	15.012 mm	26.465 mm	15–40 mm
径向误差	0.836 mm	0.084 mm	1.294 mm	≤ 1.3 mm
棒轴倾角	0.736°	0.153°	1.612°	$\leq 2^\circ$




图 6: 六孔强扰动工况下 Residual PPO 成功回合的终端几何指标及其与成功约束的关系：(a) 径向误差；(b) 棒轴倾角；(c) 插入深度。圆点表示均值，横线表示最小值至最大值范围，灰色区域表示允许区间。

最大径向误差 1.294 mm 接近 1.3 mm 门限，但仍满足成功约束；最大倾角 1.612° 、最大插入深度 26.465 mm 也均处于允许范围内。因此，本次成功率提升并非通过放宽成功判据或增加插入深度风险获得。

图7进一步给出六孔指定目标插入的一条代表性成功终止帧。图中六个孔的实体碰撞套筒在整个执行过程中同时存在，策略仅根据目标孔条件选择其中一个孔完成插入，因此该结果并非将单孔控制器在无干扰场景下简单重复六次，而是在多孔碰撞环境中完成条件化目标选择与插入。




图 7: 六孔指定目标插入中的一条代表性成功终止帧；执行过程中六个孔的碰撞几何均保持存在。

4. 训练配置对照与结果讨论

4.1. 训练配置对照

六孔任务早期训练中曾采用较高学习率、更多单轮 PPO 更新次数、较小初始策略噪声和较弱残差约束，在最终强扰动工况下成功率约为 50.78%。将训练参数调整为更保守的更新配置后，成功率提高至 100%，见表9。

表 9: 六孔任务训练配置调整前后对比。

训练配置	学习率	PPO 更新次数	初始噪声	残差正则系数	强扰动结果
调整前	10^{-4}	2	0.005	10	约 50.78%
最终配置	10^{-5}	1	0.03	100	100%

该结果与“强教师附近进行小幅修正”的设计目标一致：较低学习率、较少更新次数和更强教师偏离约束能够减少策略在训练过程中对稳定教师行为的破坏。

4.2. 残差强化学习的作用边界

基准工况下几何教师已经达到 100%，说明强化学习并不是完成任务可达性的必要条件。其价值主要体现在名义模型与实际执行之间存在偏差时：教师提供基本运动方向和阶段切换逻辑，Residual PPO 则在其附近学习局部修正。因此，

本项目验证的并不是“强化学习替代解析控制”，而是“解析控制与局部数据驱动补偿相结合”在强扰动条件下的性能优势。

4.3. 六孔任务的条件控制特性

六孔任务不是将单孔控制器独立执行六次。策略需要同时处理目标孔 one-hot 条件、阵列整体随机位置、六个孔同时存在的接触环境以及不同目标对应的横向运动距离，其策略形式可表示为

$$\pi(\mathbf{a} \mid \mathbf{o}, \mathbf{c}_i). \quad (29)$$

因此，六孔结果能够进一步说明当前方法具有从单目标插入扩展到条件多目标插入的能力，但暂时不能据此推断对任意孔数量、不同阵列拓扑或更大工作空间的泛化性能。

4.4. 失败模式与当前研究边界

最终对比中，几何教师的失败主要表现为超时，过深插入为 0，说明当前深度约束与阶段切换机制能够有效避免明显的插入深度失控。Residual PPO 主要通过减少超时提高成功率，而不是以更大的倾角或更深插入换取成功。

同时，当前最终评估主要使用随机种子 42，且仍处于仿真阶段。因此，当前阶段的结论是：在本文给定 Isaac Lab 模型、扰动范围和统一评估工况下，有界 Residual PPO 相对于固定几何教师表现出更高的插入成功率。

(四) 研究体会、结论与后续工作 本部分在总结研究结论之前，结合项目推进过程中具有代表性的失败与方法调整，说明对本次研究过程的认识，并给出任务完成情况与下一阶段工作。

1. 研究过程中的思考与体会

回顾整个项目的推进过程，我认为最重要的收获是逐渐建立了一套更可靠的问题分析和实验推进方式。项目早期曾出现过孔尺寸设置错误、成功判据不完整以及坐标参考系不一致等问题，其中部分错误甚至一度产生了非常“好看”的训练结果。这些经历使我认识到，对于强化学习控制任务而言，**首先需要验证的不是策略是否能够学会，而是环境、几何关系、观测量和评价指标本身是否可信**。如果底层模型或成功条件存在问题，继续增加训练轮数或调整奖励权重只会放大错误，而不会带来真正有效的结果。因此，后续工作中我逐渐形成了先通过确定性控制、几何量检查、碰撞反例和批量测试验证任务可解性，再进入策略训练的习惯。

另一个比较深的体会是，“**成功率高**”并不等于**研究问题已经解决**。在项目中，单孔基线曾经达到 100% 成功率，但进一步检查后发现部分轨迹存在明显的过深插入，且不同并行环境数量下的表现并不一致。这个过程让我意识到，面对看起来理想的结果，更需要主动寻找反例并检查其物理合理性，而不是急于把数字作为最终结论。此后我在评估中开始同时记录成功、超时、过深插入、终端径向误差、倾角和不同环境设置下的一致性，并将小样本结果更多用于筛选，而把较大规模的独立评估作为模型选择依据。相比单一成功率，这种做法虽然增加了实验工作量，但也显著提高了结果的可信度。

项目中最大的思路转变发生在宽工作空间下的 PPO 迁移长期效果不理想之后。前期我尝试过课程学习、奖励重构、深度屏障、对准门控、XY 辅助、目标条件 IK 以及多种 PPO 微调方式，其中不少分支能够在局部或小样本上得到改善，但扩大评估范围后并没有形成稳定增益。继续沿着“再调一个参数、再训练更久”的方向推进，边际收益已经很低。之后我重新把问题拆分为“任务是否在几何和动力学上可达”与“策略能否在扰动和分布变化下稳定完成任务”两个层次，并使用解析几何控制器单独验证前者。几何控制器在更大工作空间和目标孔径下稳定完成任务后，问题才真正从“机械臂是否做不到”收敛为“学习策略存在观测/动作分布失配和扰动适应不足”。这一步也直接促成了后续“冻结几何教师，仅由强化学习学习有界残差”的方法设计。对我而言，这比单纯继续提高 PPO 训练轮数更重要，因为它使强化学习在整个控制系统中的作用被重新定义得更加清楚：RL 不必重新学习已经能够由几何先验可靠描述的主运动，而应把有限的学习能力集中在解析模型难以覆盖的局部误差和扰动补偿上。

因此,这次项目虽然经历了较多失败路径,但这些弯路并非完全无效。它们让我对科研推进方式有了更具体的认识:从最初较为直接的“训练-观察成功率-继续调参”,逐渐转变为“提出假设-设置对照-定位失败模式-建立可信基线-再决定是否学习”。我也更加重视负结果本身的价值:一个失败实验如果能够排除一种解释、暴露一个隐藏变量,或者促使方法结构发生改变,就仍然是有效的研究证据。后续无论继续开展正式 FR3 模型、视觉/力觉闭环还是实机实验,我希望继续保持这种先验证问题、再设计方法、最后用统一条件检验结论的推进方式,而不是只以最终成功率作为研究是否有效的唯一标准。

2. 主要结论

本文完成了从随机单孔到六孔指定目标插入的 Franka 机械臂仿真研究,并形成了由几何先验与残差强化学习组成的分层控制方法。主要结论如下:

1. 通过完整六维操作空间控制与三阶段几何教师,可以在 23mm 孔径、随机目标位置和 Peg 安装不确定性条件下建立稳定的名义插入行为,单孔与六孔基准工况均达到 100% 成功率;
2. 在孔位估计偏置、动作噪声和控制增益扰动共同作用下,固定几何教师性能下降,说明解析策略对未建模误差仍存在敏感性;
3. 有界 Residual PPO 能够在保持教师基本插入逻辑的同时学习局部动作修正:单孔强扰动工况下成功率由 92.97% 提升至 96.88%,六孔强扰动工况下由 85.94% 提升至 100%;
4. TensorBoard 训练记录表明,最终残差修正幅值始终远低于理论上限:单孔与六孔最后 50 轮残差 RMS 分别约占 $\alpha = 0.15$ 的 1.63% 和 2.89%,说明性能增益主要来自教师附近的小幅局部补偿;
5. 六孔 Residual PPO 的终端径向误差、棒轴倾角和插入深度仍满足原有成功约束,表明性能提升没有依赖放宽成功判据;

3. 局限性与后续工作

当前研究仍存在以下限制:

1. 当前机器人模型基于 Isaac Lab Franka Panda 资产,尚未完成正式 FR3 模型与工具坐标系校准;
2. 结果仅在物理仿真中验证,尚未覆盖真实摩擦、结构柔性、关节回差、传感器时延和接触噪声;
3. 感知链路仍以带误差相对位移作为策略输入,尚未从视觉或力觉原始信号

形成完整闭环；

4. 最终评估未加入动作延迟，因此不能据此判断系统的时延鲁棒性；
5. 强扰动结果主要基于单一随机种子，缺少多随机种子统计与置信区间；
6. 单孔与六孔任务为适应不同训练阶段采用了不同的环境奖励组合，训练回报数值不能直接跨任务比较；
7. 训练配置对照同时改变多个超参数，后续应补充学习率、残差约束和探索噪声的单因素消融；

下一阶段可依次开展如下实验：正式 FR3 模型导入与参数校准、视觉/力觉感知链构建、接触参数与系统参数随机化扩展、多随机种子统计和单因素消融，最后按照低速、低力和分阶段验证原则开展实机实验。由此可逐步判断仿真中观察到的残差补偿优势是否能够迁移至真实机器人系统。